

7 תרגיל מספר 3: LSTM, REINFORCE ו-A2C-

להמלצת אימונים

בתרגיל הזה אתם תבנו צינור (Pipeline) מפושט של למידת חיזוק להמלצת אימוני כושר, תוך שימוש במסד נתונים אמיתי שתורידו מ-Kaggle. המטרה היא לחבר שלושה רעיונות לכדי צינור אחד קוהרנטי:

1. להשתמש בנתוני אימון היסטוריים כדי לבנות מצבים יומיים של מתאמן.
2. לאמן רשת LSTM שתקרב את האופן שבו מצב המתאמן מתפתח לאורך זמן.

3. להשתמש במודל המעברים הנלמד הזה כסביבה (Environment) עבור שיטות גרדיאנט המדיניות, שימליצו על האימונים הבאים.

הערה חשובה לגבי הציון: בכדי לחסוך בטוקנים, ניתן לעבוד עם בסיס נתונים קטן יותר, ובלבד שעקרון האימון והתוצאה יראו הבנה של הנושא. הציון אינו ניתן על מידת איכות אימון המודל, אלא מתייחס לאופן מימוש הפרויקט, להבנת הנושא וליכולת הניתוח וההסבר.

התרגיל בנוי מששה חלקים: (A) ניסוח הבעיה, (B) הורדת הנתונים והכנתם, (C) מימוש מודל LSTM, (D) מימוש REINFORCE, (E) מימוש A2C, ו-(F) ניתוח ודיון.

7.1 חלק A – ניסוח הבעיה

המטרה היא למדל את תכנון האימונים כבעיית קבלת החלטות סדרתית. בכל יום או מפגש אימון, הסוכן בוחר את סוג האימון הבא עבור המתאמן. המטרה ארוכת-הטווח היא לשפר את איכות האימון, תוך הימנעות מעומס יתר (Over-load) ומחוסר איזון. עליכם לנסח את הבעיה כתהליך החלטה מרקובי (MDP), או כתהליך מרקובי בקירוב.

7.1.1 הרכיבים שעליכם להגדיר

- מצב s_t – ייצוג קומפקטי של מצב המתאמן בזמן האחרון.
- פעולה a_t – סוג האימון שמוקצה בזמן t .
- תגמול r_t – ערך משוב סקלרי, שמשקף האם האימון שנבחר היה מועיל.
- מעבר $P(s_{t+1} | s_t, a_t)$ – לא ידוע במציאות, ויקורב בהמשך באמצעות ה-LSTM.

האינטואיציה: מצב המתאמן בזמן t אינו מוגדר רק על-ידי האימון הנוכחי. הוא תלוי בהיסטוריה של המפגשים הקודמים, בעייפות המצטברת, ובאופן שבו נפח האימון התחלק בין קבוצות השרירים. בדיוק בגלל זה אנחנו משתמשים במודל סדרתי: מעבר המצב תלוי-היסטוריה, וה-LSTM הוא דרך טבעית למדל תלות זמנית כזו.

7.1.2 תוצרי חלק A

הגדרה מדויקת בכתב של המצב, הפעולה והתגמול; הסבר קצר מדוע המלצת אימונים היא באופן טבעי בעיית החלטה סדרתית; ותרשים או סקיצת פסאודו-קוד של צינור הלמידה.

7.2 חלק B – מסד הנתונים להורדה

בתרגיל זה תעבדו עם מסד נתוני אימונים אמיתי מ-Kaggle, המכיל הן רשומות מפורטות ברמת התרגיל והן סיכומים ברמת התוכנית.

- שם: 600K+ Fitness Exercise & Workout Program Dataset.

- מחבר: Adnane Louardi.

- עמוד מסד הנתונים:

<https://www.kaggle.com/datasets/adnelouardi/600k-fitness-exercise-and-workout-program-dataset>

- קבצים:

program_summary.csv,

programs_detailed_boostcamp_kaggle.csv

לפי כרטיס מסד הנתונים, הוא מכיל 605033 רשומות תרגיל בודדות בקובץ המפורט, ו-2598 תוכניות כושר ייחודיות בקובץ הסיכום.

7.2.1 מדוע מסד הנתונים הזה מתאים

מסד הנתונים מספק שתי רמות עבודה: **נתונים מפורטים** ברמת התרגיל (שם התרגיל, סטים, חזרות, עצימות, שבוע, יום וזמן), וכן **מטא-נתונים** ברמת התוכנית (כותרת, תיאור, רמה, מטרה, ציוד, אורך התוכנית, זמן לאימון וסך התרגילים). כך אפשר להשתמש בשורות המפורטות כדי לבנות רצפים ברמת היום, ובקובץ הסיכום כדי לבחור תוכנית אימונים קוהרנטית שתגדיר מסלול של מתאמן סינתטי אחד.

7.2.2 הוראות הורדה ישירה

עליכם להחזיק חשבון Kaggle ולהיות מחוברים לפני ההורדה. **אפשרות 1 – דרך הדפדפן:** פתחו את עמוד מסד הנתונים, לחצו על כפתור ה-Download, שמרו וחלצו את קובץ ה-ZIP, וודאו ששתי קבצי ה-CSV קיימים. **אפשרות 2 – דרך ה-Kaggle API:**

הורדה דרך Kaggle API

```
kaggle datasets download -d adnanelouardi/600k-fitness-exercise-and-workout-program-dataset
unzip 600k-fitness-exercise-and-workout-program-dataset.zip
```

7.2.3 תוכן הקבצים

הקובץ program_summary.csv – שורה אחת לכל תוכנית אימון, עם תיאור ברמה גבוהה. שדות צפויים: goal, level, description, title, program_length, equipment (משך בשבועות), time_per_workout, total_exercises, ו-last_edit/created.

הקובץ programs_detailed_boostcamp_kaggle.csv – רשומות ברמת התרגיל. שדות צפויים: כותרת ותיאור התוכנית, מזהי שבוע ויום, שם התרגיל, סטים וחזרות, עצימות, רמת כושר, מטרה, ציוד וזמן לאימון.

שימו לב: כרטיס מסד הנתונים מציין במפורש כי **ערכים שליליים** בשדות sets או reps עשויים לייצג **זמן בשניות**. לכן עליכם לבדוק את המקרים האלה בקפידה בשלב העיבוד המקדים.

7.2.4 בניית מתאמן סינתטי אחד

עליכם לבנות את הצינור סביב מתאמן סינתטי אחד, הנגזר מתוכנית אימון אחת שנבחרה.

1. **בחירת תוכנית:** פתחו את `program_summary.csv` ובחרו תוכנית רב-שבועית ריאליסטית – למשל תוכנית כוח או היפרטרופיה. סננו לפי קריטריונים כמו `equipment = Full Gym` ו-`program_length` של 8 שבועות ומעלה, ו-`time_per_workout` בין 45 ל-120 דקות. רשמו את המזהה כ-`chosen_program`.
2. **חילוץ השורות המפורטות:** פתחו את הקובץ המפורט ושמרו רק את השורות השייכות ל-`chosen_program`.
3. **בניית מפגשים יומיים:** קבצו את השורות לפי `week` ו-`day`. עבור כל יום t חשבו לפחות את התכונות הבאות:

$$(13) \quad \text{total_volume}_t = \sum_i (\text{sets}_i \cdot \text{reps}_i)$$

וכן `muscle_distribution_t` (נפח מנורמל לכל קבוצת שריר), `session_duration_t`, `week_index_t` ו-`day_in_cycle_t`. אם לצירוף שבוע-יום אין אימון, הוסיפו **יום מנוחה** (Rest Day) עם נפח אפס.

יצירת מסלול המתאמן: "שטחו" את התוכנית לרצף מסודר אחד של ימים, $(s_1, s_2, \dots, s_T)$, כאשר כל איבר מתאים ליום אחד. הרצף הזה הוא המסלול (Trajectory) של המתאמן הסינתטי, ועליו נשען כל מה שבא בהמשך.

7.3 חלק C – מימוש מודל LSTM

מסד הנתונים סדרתי ברמת התוכנית: מה שצריך לקרות ביום $t + 1$ תלוי במה שקרה בימים הקודמים. יום בודד עדיין אינו מספיק כדי לאפיין את מצב המתאמן – ההשפעה של האימון היום תלויה בעומס האחרון, באיזון בין קבוצות השרירים, ובשאלה אם הימים הקודמים היו עצימים או של מנוחה. לכן ה-LSTM משמש ללמידת **מודל מעברים** (Transition Model) שלוכד תלות זמנית:

$$(14) \quad s_{t+1} \approx f_\phi(s_t, a_t, h_t)$$

כאשר s_t הוא המצב הנוכחי, a_t הפעולה שנבחרה, h_t הייצוג החבוי שה-LSTM לומד, ו- f_ϕ חוזה את המצב הבא.

7.3.1 המימוש הנדרש

1. הגדירו וקטור מצב s_t , למשל: עומס מתגלגל של 7 ימים, ציון איזון בין קבוצות שרירים, ממוצע משך מפגש, ומדד שבוע או יום-במחזור.
2. הגדירו מרחב פעולות a_t : המירו את האימונים היומיים למספר קטן של סוגי אימון – למשל קבצו את המפגשים ל-4 עד 8 קטגוריות לפי נפח, דגש שרירי ומשך. כל אשכול הופך לפעולה בדידה אחת.
3. בנו מודל LSTM שמקבל רצף של מצבים ופעולות אחרונים, וחוזה את המצב הבא.
4. אמנו את ה-LSTM בלמידה מונחית (Supervised) על חלונות רצופים מתוך מסלול המתאמן.

הערה חשובה: למרות שמסד הנתונים מכיל תוכניות ולא מדידות פיזיולוגיות, הוא עדיין שימושי כי הוא מספק **דפוסי אימון זמניים מובנים** שניתן להמיר למעברי מצב. ה-LSTM אינו הממליץ הסופי, אלא קירוב נלמד של סביבת האימון. תוצרי חלק C: הגדרת s_t ו- a_t , תיאור ארכיטקטורת ה-LSTM, עקומות Loss לאימון ולוולידציה, ודיון אם המודל לוכד דפוסים זמניים בעלי משמעות.

7.3.2 הקשר תיאורטי: מודל עולם (World Model)

חשוב שתכירו את השם התיאורטי המדויק למה שאתם בונים כאן. כאשר רשת זיכרון (LSTM) נלמדת מתוך נתונים היסטוריים כדי לשמש **מייצרת סביבה** (Environment) שבתוכה הסוכן מתאמן, התהליך מכונה בנייה של **מודל עולם** (World Model) – מושג שהתקבע אקדמית בעקבות עבודתם של דייוויד הא ויורגן שמידהובר [7], והוא לב התחום של Model-Based RL. רשת הזיכרון מאפשרת לבנות פונקציית מעברים התלויה במצב החבוי h_t , ובכך היא הופכת בעיה של תצפית חלקית, שבה חוק מרקוב נפגע (POMDP), חזרה לבעיית קבלת החלטות מרקובית שניתן לפתור. הכירו את המונח World Model – כך תפגשו אותו בכנסים ובמאמרים בהמשך דרככם.

7.4 חלק D – מימוש REINFORCE מעל מודל ה-LSTM

המטרה: להשתמש במודל המעברים המאומן כסביבה, ולאמן מדיניות באמצעות REINFORCE כדי לבחור פעולות אימון לאורך זמן. המדיניות תפעל על רצף המצבים הסינתטי שבניתם, ולא ישירות על שורות ה-CSV הגולמיות.

7.4.1 ניסוח המדיניות

תהי המדיניות $\pi_\theta(a_t | s_t)$, כאשר הפעולה היא סוג האימון הבא. המדיניות מיוצגת על-ידי רשת נוירונים שמקבלת את המצב הנוכחי ומוציאה התפלגות קטגוריאלית מעל סוגי האימונים. תייצרו אפיזודות באורך קבוע (למשל 28 ימים), ובכל צעד: צופים את s_t , דוגמים פעולה $a_t \sim \pi_\theta(a_t | s_t)$, משתמשים ב-LSTM כדי לחזות את s_{t+1} , מחשבים תגמול r_t , וממשיכים עד סוף האפיזודה.

7.4.2 עיצוב התגמול

הגדירו תגמול שמעודד אימון פורה אך מאוזן, למשל:

$$(15) \quad r_t = \text{gain}_t - \lambda_1 \cdot \text{overload_penalty}_t - \lambda_2 \cdot \text{imbalance_penalty}_t$$

כאשר gain_t מתגמל נפח אימון מועיל, $\text{overload_penalty}_t$ מעניש עומס מתגלגל מופרז, ו- $\text{imbalance_penalty}_t$ מעניש חלוקה לא-מאוזנת בין קבוצות השרירים.

7.4.3 עדכון REINFORCE

אמנו את המדיניות לפי כלל גרדיאנט המדיניות האפיזודי (ראו משוואה 2 בפרק התיאורטי):

$$(16) \quad \theta \leftarrow \theta + \alpha \sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) G_t$$

כאשר G_t היא התשואה מזמן t . תוצרי חלק D: תיאור רשת המדיניות, תהליך יצירת האפיזודות, הגדרת התגמול והנמקתו, עקומות אימון של התשואה האפיזודית הממוצעת, גרף אבחון נוסף (כמו שונות התגמול או העומס השבועי הממוצע), ודיון בחוסר היציבות (Variance) שנצפה ב-REINFORCE.

7.5 חלק E – מימוש A2C מעל מודל ה-LSTM

ממשו Advantage Actor–Critic (A2C) על אותה סביבה מדומה מחלק D. המוטיבציה: להשוות שיטת גרדיאנט מדיניות טהורה (מונטה-קרלו) לשיטת שחקן-מבקר בעלת שונות נמוכה יותר.

7.5.1 מבנה המודל

ל-A2C שני רכיבים נלמדים: **שחקן** (Actor) – המדיניות $\pi_\theta(a_t | s_t)$; ו**מבקר** (Critic) – אומדן ערך $V_\psi(s_t)$. השחקן בוחר פעולות אימון, והמבקר מעריך עד כמה טוב מצב המתאמן הנוכחי תחת המדיניות הנוכחית. אומדן היתרון:

$$(17) \quad A_t = r_t + \gamma V_\psi(s_{t+1}) - V_\psi(s_t)$$

לאחר מכן בצעו אופטימיזציה: את **השחקן** בעזרת גרדיאנט המדיניות המשוקלל ב- A_t , ואת **המבקר** בעזרת Loss של ערך, כמו ריבוע שגיאת ה-TD. תוצרי חלק E: תיאור רשתות השחקן והמבקר, היעד המדויק שבו השתמשו, עקומות אימון של התגמול הממוצע, והשוואה בין A2C ל-REINFORCE מבחינת יציבות ויעילות-דגימה.

7.6 חלק F – ניתוח ודיון

בחלק האחרון הרהרו על הצינור כולו ודונו במשמעות התוצאות. עליכם להתייחס לשאלות הבאות:

1. האם נראה שה-LSTM לומד מבנה זמני ריאליסטי מהתוכנית שנבחרה?
2. האם המדיניות לומדת המלצות אימון מאוזנות, או שהיא "קורסת" לחזרה על מספר קטן של פעולות?
3. האם A2C יציב יותר מ-REINFORCE בהקשר הזה?
4. מהן המגבלות העיקריות של שימוש בנתוני תוכניות אימון, במקום נתוני תוצאה אמיתיים של משתמשים?
5. כיצד אפשר היה לשפר את המערכת אילו היו זמינות מדידות של דופק, כאבי שרירים, התאוששות או התקדמות בכוח?

7.6.1 נקודות לדיון ותוצרים

עליכם להכיר בכך שזוהי **הגדרת המלצה מפושטת**, ולא סימולטור פיזיולוגי מלא. מסד הנתונים מספק רצפי אימון מובנים ומטא-נתונים שימושיים, אך אינו מודד ישירות תוצאות כמו גדילת שריר, עייפות, סיכון לפציעה או מצב התאוששות. לכן עיצוב התגמול ובניית המצב הם בחלקם היוריסטיים – ואת המגבלה הזו יש לדון בבירור.

שילוב ידע מומחה – מיסוך פעולות (Action Masking): סוכן הלומד במנותק מאילוצי העולם האמיתי עלול להציע פעולות לא סבירות או מסוכנות (למשל, העמסת משקל רב מדי שעלולה לגרום לפציעה). פתרון מקובל למעבר מתיאוריה לפרקטיקה הוא הזרקת ידע אנושי-מומחה ישירות אל מנגנון הלמידה, לרוב באמצעות טכניקת **מיסוך פעולות (Action Masking)**. הטכניקה מאפסת בהסתברות קשיחה כל בחירה שאינה עומדת בהגדרות הבטיחות – מבחינה מעשית, קובעים את הלוג של אותן פעולות ל- $-\infty$ עוד בתוך חישוב וקטור המדיניות – תוך שימור גמישות הלמידה במרחב הפעולות המותרות בלבד [8]. כך משולבים "מעקות בטיחות" (Guardrails) אנושיים לצד האופטימיזציה הלומדת. אם תרצו, תוכלו להציע בדיון כיצד מיסוך כזה היה משתלב בתוכנית האימונים שלכם.

תוצרי חלק F: טבלת השוואה בין REINFORCE ל-A2C, דיון ביקורתי קצר במגבלות מסד הנתונים, והצעה קצרה להרחבת הפרויקט עם נתונים עשירים יותר.

7.7 רשימת הגשה

ההגשה שלכם תכלול: קוד לטעינת הנתונים ולעיבוד המקדים; שיטה מתועדת לבחירת תוכנית אחת מ-Kaggle; מסלול מתאמן סינתטי ברמת היום; מימוש ה-LSTM ועקומות ה-Loss; מימוש REINFORCE עם גרפי אימון; מימוש A2C עם גרפי אימון; וסעיף דיון מסכם.

מסד הנתונים לשימוש בחלק B:

<https://www.kaggle.com/datasets/adnanelouardi/600k-fitness-exercise-and-workout-program-dataset>

קבצים עיקריים:

program_summary.csv,

programs_detailed_boostcamp_kaggle.csv